

Strang 教授线性代数笔记

说明：单位矩阵： I ；声明的向量都是列向量， \vec{a} 、 \mathbf{a} 都表示列向量。

课程视频：<https://www.youtube.com/playlist?list=PL6839449936471E0C>

pdf版参见：<https://github.com/zyj-nova/LinearAlgebraNotes>

1. 矩阵消元、矩阵的秩与转置（基础）

1.1 矩阵的初等变换

矩阵初等行变换：

- 对换两行
- 以数 $k \neq 0$ 乘某一行中所有元（数乘）
- 把某一行所有元的 k 倍加到另一行对应的元上去

把“行”换成“列”，即为矩阵的初等列变换。矩阵的初等行变换和初等列变换统称为初等变换。

初等矩阵：由单位矩阵 I 经过一次初等变换得到的矩阵成为初等矩阵。

性质：设矩阵 A 是一个 $m \times n$ 矩阵，则矩阵 A 的初等行变换可以表示为左乘多个 m 阶初等矩阵 E ，即：

$E_1 E_2 \cdots E_n A$ ；矩阵 A 的初等列变换可以表示为右乘多个 n 阶初等矩阵 E ，即：
 $A E_1 E_2 \cdots E_n$ 。

注意：这里的左右指矩阵 A 的左右。

例子：

$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ ，交换单位阵的两行得到初等矩阵 $E = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ ，则 $EA = \begin{bmatrix} c & d \\ a & b \end{bmatrix}$ ，即交换了矩阵 A 的两行。

E 也可以视为交换单位阵的两列得到，那么 $AE = \begin{bmatrix} b & a \\ d & c \end{bmatrix}$ ，即交换 A 的两列。

行阶梯形矩阵

非零矩阵满足：

1. 非零行在零行（一行全为0）的上面
2. 非零行的第一个非零元素所在列在上一行（如果存在）的第一个非零元素所在列的右面。

例如： $B = \begin{pmatrix} 1 & 1 & -2 & 1 & 4 \\ 0 & 1 & -1 & 1 & 0 \\ 0 & 0 & 0 & 1 & -3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$

行最简形矩阵

在阶梯形矩阵中，若非零行的第一个非零元素全是1，且非零行的第一个元素1所在列的其余元素全为零，就称该矩阵为行最简形矩阵。

利用初等行变换，把一个矩阵化为行阶梯形矩阵和行最简形矩阵，是一种很重要的运算。

例如对上述行阶梯矩阵 B 进行初等行变换得到： $\begin{pmatrix} 1 & 0 & -1 & 0 & 4 \\ 0 & 1 & -1 & 0 & 3 \\ 0 & 0 & 0 & 1 & -3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$

行最简形矩阵(或者行阶梯形矩阵)的非零行个数即为矩阵的秩 (**rank**)。

若通过初等行变换可以得到形如 $R = \begin{pmatrix} I_{r \times r} & F_{r \times (n-r)} \\ O & O \end{pmatrix}$ 的简化矩阵 (上述 B 就不符合以下情况)，那么就有如下结论：

很重要!!!!: $RN = 0 \Rightarrow N = \begin{pmatrix} -F \\ I \end{pmatrix}$, I 的阶数等于自由变量的个数。可以看出对系数矩阵初等变换为形如 R ，解向量就可以写成 N 的形式。

接着考虑 $(I \quad F) \begin{pmatrix} x_{pivot} \\ x_{free} \end{pmatrix} = 0 \Rightarrow x_{pivot} = -Fx_{free}$

利用初等行变换求方阵的逆矩阵 (高斯-约旦消元法) (Lecture 10的内容)

A 为可逆 n 阶方阵，将矩阵 (A, I) 经过初等行变换可以得到 (I, E) ， I 为单位矩阵，则 E 为矩阵的逆矩阵。实际上，矩阵 E 是由单位阵变换而来的，在对 (A, I) 进行行变换的过程中， E 记录了整个变换过程。

$$R(A, I) = (I, E)$$

$$RA = I, RI = E \Rightarrow R = E = A^{-1}$$

R 表示初等行变换矩阵。

从初等变换角度理解矩阵乘法: $A_{m \times n} B_{n \times p} = C_{m \times p}$

从 A 的角度，相当于 A 右乘矩阵 B 中的每个列向量， C 中每列都是 A 中列向量的线性组合。

从 B 的角度，相当于 B 左乘 A 中每个行向量， C 中每行都是 B 中行向量的线性组合。

注意：矩阵的初等行变化不会改变线性方程组的解，初等列变换会改变解（交换两列相当于把两个未知数的系数交换了。方程组也就变了）。

1.2 矩阵的转置

A 为 $m \times n$ 的矩阵， A^T 称为 A 的转置矩阵，且 $(A)_{ij} = (A^T)_{ji}$ 。（行变列，列变行）。

性质：

- $(A+B)^T = A^T + B^T$
- $(\lambda A)^T = \lambda A^T$
- $(AB)^T = B^T A^T$
- 若 A 为方阵, 且 $A = A^T$, 则 A 为对称矩阵
- $A^T A$ 是一个 n 阶对称阵, $(A^T A)^T = A^T (A^T)^T = A^T A$

1.3 矩阵的逆

定义: $AB = BA = I$, 则 A 、 B 互为逆矩阵。

可逆矩阵又称为非奇异矩阵, 不可逆矩阵被称为奇异矩阵。

方阵 A 可逆的充要条件是 $|A| \neq 0$ 。

方阵 A 可逆的充要条件是 A 可以通过初等行变换得到单位阵。

- 证明: A 可逆 \Leftrightarrow 存在可逆矩阵 P , $PA = I \Leftrightarrow A$ 行变换得到 I

逆矩阵的性质

若 n 阶矩阵 A 可逆, 有

- $(A^{-1})^{-1} = A$
- 数 $\lambda \neq 0$, $(\lambda A)^{-1} = \frac{A}{\lambda}$
- B 与 A 同阶数, 且可逆, $(AB)^{-1} = B^{-1} A^{-1}$

证明: $P(AB) = I \Rightarrow PAB B^{-1} = I B^{-1} \Rightarrow PA = B^{-1} \Rightarrow P = B^{-1} A^{-1}$

- A^T 亦可逆, 且 $(A^T)^{-1} = (A^{-1})^T$
- $|A| \neq 0$
- $|A^{-1}| = \frac{1}{|A|}$

证明: A 可逆 $\Rightarrow AA^{-1} = E \Rightarrow |A| * |A^{-1}| = |E| = 1 \Rightarrow |A^{-1}| = \frac{1}{|A|}$

- A 满秩矩阵。由于 $|A| \neq 0$, 则 A 的最高阶子式为自身且不为 0, 因此 $R(A) = n$, 即满秩。

1.4 矩阵与向量乘法

- Ax 相当于 A 的列向量的线性组合, 结果是列向量 $x_1 c_1 + x_2 c_2 + \dots$ 对应列乘以 \vec{x} 的分量然后所有列求和
- xA 相当于 A 的行向量的线性组合, 结果是行向量 $x_1 r_1 + x_2 r_2 + \dots$ 对应行乘以 \vec{x} 的分量然后所有行求和

1.5 矩阵的秩

2. 向量空间、列空间、零空间 (进阶)

给定 $m \times n$ 的矩阵 A

2.1 向量空间的定义 (只讨论实数)

定义: 以向量为元素的集合 V 称为向量空间 (vector space)。

向量空间必须满足:

- 对加法运算封闭，任意两个向量相加得到的向量仍在空间内
- 对数乘运算封闭，乘以任意实数仍在空间内
- 包含一个零向量（当非零向量数乘0得到零向量，因此必须包含）

\mathbb{R}^n 表示含有 n 个元素的向量且基向量个数为 n （维度为 n ）组成的向量空间。

子空间（**subspace**）满足以上三条性质却又不包含所有向量的空间。（向量空间内的向量空间）

例子： \mathbb{R}^2 的子空间：整个二维平面；二维平面内，过原点的任意直线；零向量 $\vec{0} = (0, 0)$ 。

向量空间 P ，两个 S 中子空间 S, I 。两个子空间的并并不是一个子空间，两个子空间的交是一个子空间。

即： $S \cap I \in P, S \cup I \notin P$ 。

2.2 列空间

定义：矩阵 A 的列向量的线性组合（数乘和加法运算）构成了矩阵 A 的列空间，记为 $C(A)$ 。

同理，定义矩阵 A 的行向量的线性组合，构成了 A 的行空间，记为 $R(A)$ 。

考虑 $A = \begin{pmatrix} 1 & 3 \\ 2 & 3 \\ 4 & 1 \end{pmatrix}$ ， $C(A)$ 构成了三维空间中的一个过原点的平面。

考虑 $A = \begin{pmatrix} 1 & 1 & 2 \\ 2 & 1 & 3 \\ 3 & 1 & 4 \\ 4 & 1 & 5 \end{pmatrix}$ ， $C(A)$ 是 \mathbb{R}^4 的一个子空间（每一列含有4个元素）。 $C(A)$ 的维数

为2，是四维空间的一个平面（第三列是前两列的线性组合，因此前两列作为列空间的基）。

考虑线性方程组 $Ax = b$ ，是否始终有解？答案是当 \vec{b} 不在 $C(A)$ 内时，方程无解。因为 Ax 相当于矩阵列向量的线性组合，若 \vec{b} 不在列空间，必然无解。只有 \vec{b} 是 A 中各列的线性组合时，即 $\vec{b} \in C(A)$ ，方程才有解。

2.3 零空间 (核) null space

定义： $Null(A) = \{x | Ax = 0, x \in \mathbb{R}^n\}$ ，齐次线性方程组的解构成了 A 的零空间。

定理：零空间的维数 $\dim N(A) = n - R(A) = n - \dim C(A)$ ， n 为列数；也就是自由变量的个数，主元的个数就是矩阵的秩。

3. 向量组的线性相关性、基、维数

3.1 向量组的线性相关性 (independence)

定义：给定向量组 $A : a_1, a_2, \dots, a_m$ ，如果存在不全为0的数 k_1, k_2, \dots, k_m ，使

$$k_1 a_1 + k_2 a_2 + \dots + k_m a_m = 0$$

则称向量组 A 是线性相关的 (linearly dependent)，否则称它线性无关 (linearly independent)。

若向量组线性无关，则向量组向量的线性组合始终不为 $\vec{0}$ （不包括系数全为0的情况）

向量组能线性组合得到零向量：相关；线性组合得不到零向量：无关。

随之可以与线性方程组的解联系起来。设向量组构成的矩阵 $A_{n \times m}$ ，线性方程组 $Ax = \vec{0}$ ， $x \in \mathbb{R}^m$

- 线性相关： $N(A)$ 有非零解。 $R(A) < m$ ，含有自由变量。
- 线性无关： $N(A)$ 只包含一个零向量。 $R(A) = m$ ，所有分量都是主元，没有自由变量。

3.2 基、维数

定理：对于给定的向量空间，基向量的个数都是一样的。

向量空间 V 中一组线性无关的向量组称为 V 的一个基，基向量的个数称为向量空间的维数。

因此我们说 $A = \begin{pmatrix} 1 & 3 \\ 2 & 3 \\ 4 & 1 \end{pmatrix}$ 的列空间 $C(A)$ 是三维空间的一个平面，因为 $\dim C(A) = 2$ 。

“基向量的个数不多也不少。”

基向量的性质：

- 线性无关
- 线性组合生成(spanning)整个空间

若向量组构成的矩阵为方阵，若向量组线性无关，则方阵可逆（满秩矩阵 $|A| \neq 0$ ）。

例子：求矩阵 $A = \begin{pmatrix} 1 & 0 & 1 \\ 1 & -2 & -1 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{pmatrix}$ 的零空间的一组（个）基（a basis）。

就是求 $Ax = 0$ 的一个解。

对其进行行变换最终得到： $\begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$ ，可知向量 $\begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix}$ 可以作为 $N(A)$ 的一个基向量（不需要乘常数）

基向量个数为1，因此 $\dim N(A) = 1, R(A) = 2$ 。

注意！！！！教授称之为**Great theorem**的：

矩阵的秩 = 主元个数 = 矩阵列空间的维数，因为主列可以构成一组基，所以主元个数就是列空间维数。

例子： $A = \begin{pmatrix} 1 & 2 & 3 & 1 \\ 1 & 1 & 2 & 1 \\ 1 & 2 & 3 & 1 \end{pmatrix}$ ，显然第一列与第二列线性无关可以作为列空间的一组基。

经过行变换可以得到

$$\begin{pmatrix} 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

可以看出第一列与第二列是主列， $R(A) = 2 = \text{主元个数}$ 。

4. 线性方程组的解

4.1 齐次线性方程组

考虑下列方程组：

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &= 0 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 &= 0 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 &= 0 \end{aligned}$$

可以写成矩阵形式：

$$x_1 \begin{pmatrix} a_{11} \\ a_{21} \\ a_{31} \end{pmatrix} + x_2 \begin{pmatrix} a_{12} \\ a_{22} \\ a_{32} \end{pmatrix} + x_3 \begin{pmatrix} a_{13} \\ a_{23} \\ a_{33} \end{pmatrix} = \vec{0}$$

$$Ax = \vec{0}$$

其中 $A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$ ， $\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$

对 A 进行初等变换为行阶梯形矩阵，那么非零行第一个非零元素对应的列对应的未知变量我们称为主元（pivot），其余列称为自由变量。

例子：若方程系数矩阵 $A = \begin{pmatrix} 1 & 1 & -2 & 1 & 4 \\ 0 & 1 & -1 & 1 & 0 \\ 0 & 0 & 0 & 1 & -3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$ ，那么主元就是 x_1, x_2, x_4 ，自由变

量就是 x_3, x_5 。

- 例子：给定 A ，求 $Ax = 0$ 。

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 2 & 6 & 8 \\ 2 & 8 & 10 \end{pmatrix}$$

$$A \sim \begin{pmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 4 & 4 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

可知 x_1, x_2 为主元, x_3 为自由变量, 令 $x_3 = 1$ (为0时解为0向量无意义), 得到 $x = (-1, -1, 1)^T$ 。

记得初等变换讲过的解的形式: $N = \begin{pmatrix} -F \\ I \end{pmatrix}$, 这儿的 I 为1阶, 即只有元素1。 I 的阶数等于自由变量的个数。

$N(A) = c\mathbf{x}, c \in R$ 。注意: 当求零空间的基向量时才是 \mathbf{x} 。任意倍的 \mathbf{x} 生成了零空间。

求解步骤:

- 将自由变量依次设置为1, 其余自由变量为0; 带入 $A\mathbf{x} = 0$ 求出主元的值
- 有几个自由变量, 零空间就有几个向量线性组合生成
- 自由变量个数 $n - R(A)$

4.2 非齐次线性方程组

$$A\mathbf{x} = \mathbf{b}$$

增广矩阵 (A, \mathbf{b}) , 若 $R(A) = R(A, \mathbf{b}) \Leftrightarrow$ 线性方程组有解。

求解步骤:

- 将所有自由变量设为0, 带入 $A\mathbf{x} = \mathbf{b}$, 求解主元的值, 得到一个特解 \mathbf{x}_p ; ($A\mathbf{x}_p = \mathbf{b}$)
 - 求解 $A\mathbf{x} = 0$, 即求 A 的零空间 \mathbf{x}_n ($A\mathbf{x}_n = 0$)
 - 得到通解 $\mathbf{x}_n + \mathbf{x}_p$ ($A\mathbf{x}_n + A\mathbf{x}_p = \mathbf{b}$) 这就是非齐次线性方程组的解结构
- 注意: 特解不需要乘常数 c

矩阵的秩与解的个数 (仅讨论有解的情况即 $R(A) = R(A, \mathbf{b})$):

可知 $0 \leq R(A) \leq \min\{m, n\}$

- 若 $R(A) = R(A, \mathbf{b}) = n$, 即列满秩, 此时自由变量个数为0。非零行个数为 n , 相当于 n 个方程, n 个未知变量, 且 $N(A) = \mathbf{0}$, $A\mathbf{x} = \mathbf{b}$ 仅有一解 \mathbf{x}_p
- 若 $R(A) = R(A, \mathbf{b}) < n$, 此时存在自由变量, 因此有无限解, $\mathbf{x}_p + \mathbf{x}_n$, \mathbf{x}_n 是一系列向量的线性组合。
- 若 $R(A) = R(A, \mathbf{b}) = m < n$, 即行满秩, 合第二种情况相同, 无限解

考虑当 $R(A) \neq R(A, \mathbf{b})$ 的情形, 此时 A 中非零行个数不等于 \mathbf{b} 的非零行个数, 方程无解。

- 例子

给定

$$A = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & -1 \\ 1 & 3 & 1 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} 1 \\ -2 \\ 5 \end{pmatrix}$$

求 $A\mathbf{x} = \mathbf{b}$ 的解。

$$\begin{pmatrix} 1 & 1 & 2 & 1 \\ 1 & 2 & -1 & -2 \\ 1 & 3 & 1 & 5 \end{pmatrix} \sim \begin{pmatrix} 1 & 1 & 2 & 1 \\ 0 & 1 & -3 & -3 \\ 0 & 0 & 1 & 2 \end{pmatrix} (r_3 - r_2, r_2 - r_1, r_3 - r_2, r_3/2) \sim \begin{pmatrix} 1 & 0 & 0 & -6 \\ 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & 2 \end{pmatrix}$$

得 $\mathbf{x} = (-6, 3, 2)^T$ 。列满秩矩阵只有一个特解。

给定

$$A = \begin{pmatrix} 2 & 3 & 1 \\ 1 & -2 & 4 \\ 3 & 8 & -2 \\ 4 & -1 & 9 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} 4 \\ -5 \\ 13 \\ -6 \end{pmatrix}$$

求解 $A\mathbf{x} = \mathbf{b}$,

经过行变换可得

$$\begin{pmatrix} 1 & 0 & 2 & -1 \\ 0 & 1 & -1 & 2 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

主元为 x_1, x_2 , 自由变量为 x_3 , 令 $x_3 = 0$, 得 $x_1 = -1, x_2 = 2$, 特解 $\mathbf{x}_p = (-1, 2, 0)^T$

当 $x_3 = 1$, 得 $(-2, 1, 1)^T$.

因此

$$\mathbf{x} = \begin{pmatrix} -1 \\ 2 \\ 0 \end{pmatrix} + c \begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix}, c \in \mathbb{R}$$

5. 四个基本子空间

给定矩阵 $A_{m \times n}$

列空间 $C(A)$

零空间 $N(A)$: $A\mathbf{x} = \vec{0}, \mathbf{x} \in \mathbb{R}^n$

行空间 $C(A^T)$: 矩阵 A 经过初等变换后, 非零行即可作为行空间的一组基。

A^T 的零空间(左零空间) $N(A^T)$: $A^T \mathbf{x} = \vec{0}, \mathbf{x} \in \mathbb{R}^m$ 或者写成 $\mathbf{x}^T A = \mathbf{0}$ 这也是为什么叫左零空间的原因。

考虑 A 到其行最简形矩阵 R 的变换过程, 现在我们想知道 A 乘以一个什么矩阵可以变到 R , 即 $EA = R$, 求 E ?

注意 A 是任意矩阵 (方阵或者长方形矩阵) !

考虑求逆矩阵时在方阵后加上一个同阶方阵然后行变换的过程, 同样在 A 后加一个 m 阶单位阵, 有

$$(A_{m \times n}, I_{m \times m}) \rightarrow (R_{m \times n}, E_{m \times m})$$

R 为矩阵 A 的行阶梯矩阵, 此时 E 就是我们要求的那个变换矩阵, 即 $EA = R$, 此时 R 中的零行对应矩阵 E 的行就是 $N(A^T)$ 的一个基向量。

四个子空间的正交性(orthogonality)

- $C(A) \perp N(A^T)$

证明: 设 $\vec{v} \in C(A)$, $\vec{v} = A\vec{x}$, $\vec{v} \in \mathbb{R}^m$, 即列空间的线性组合, $\vec{u} \in N(A^T)$, $A^T \vec{u} = \vec{0}$, $\vec{u} \in \mathbb{R}^n$ $\vec{v}^T \vec{u} = (A\vec{x})^T \vec{u} = \vec{x}^T A^T \vec{u} = \vec{x}^T (\vec{0}) = 0$. 所以 \vec{u} 和 \vec{v} 正交, 由于两个空间的任意向量都相互正交, 因此这两个空间正交。

- $C(A^T) \perp N(A)$

证明: 显然 $N(A) = \{\vec{x} | A\vec{x} = \vec{0}\}$, 即 \vec{x} 与 A 中每个行向量正交 $\vec{r}_i \vec{x} = 0$, \vec{r}_i 是行向量。且行空间由行向量的线性组合得到, 因此 \vec{x} 与行空间任意向量正交。即 $\vec{a} = c_1 \vec{r}_1 + c_2 \vec{r}_2 \in C(A^T)$, $\vec{a}^T \vec{x} = (c_1 \vec{r}_1 + c_2 \vec{r}_2)^T \vec{x} = 0$ 。




Figure 4.2: Two pairs of orthogonal subspaces. The dimensions add to n and add to m . This is an important picture—one pair of subspaces is in \mathbb{R}^n and one pair is in \mathbb{R}^m .

6. 正交向量与投影

6.1 正交向量

给定列向量 $\vec{u}, \vec{v} \in \mathbb{R}^n$, 若 $\vec{u}^T \vec{v} = \vec{v}^T \vec{u} = 0$, 则 \vec{u}, \vec{v} 正交。零向量 $\vec{0}$ 与任意向量正交 (orthogonal)。

$\|\vec{u}\|$ 表示向量 \vec{u} 的模长, 即 $\|\vec{u}\| = \sqrt{\vec{u}^T \vec{u}}$ 。注意: $\vec{u}\vec{u}^T$ 结果是一个 $n \times n$ 的矩阵!

6.2 正交子空间与正交基

子空间 S, T , 若 S 与 T 正交, 则 S 中任意向量与 T 的任意向量正交。四个基本子空间的正交性上一章已经讨论过。

若空间的一组基向量两两正交, 就是一组正交基, 在此条件上, 若每个向量的模长为 1, 则称这组基向量为标准正交基。

例子： \mathbb{R}^3 的一组标准正交基： $\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$

6.3 投影与投影矩阵



根据上图可得：

$$\begin{aligned} \mathbf{p} &= x\mathbf{a}, x \in R \\ \mathbf{a} \perp \mathbf{e} &\Rightarrow \mathbf{a}^T(\mathbf{b} - x\mathbf{a}) = 0 \Rightarrow x\mathbf{a}^T\mathbf{a} = \mathbf{a}^T\mathbf{b} \end{aligned}$$

$$x = \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}$$

$$\mathbf{p} = \mathbf{a} \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}$$

我们称

$$P = \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T\mathbf{a}}$$

为由 \mathbf{b} 到 \mathbf{a} 的投影变换矩阵，即 $\mathbf{p} = P\mathbf{b}$ 。直观上理解，任意向量与 P 相乘，结果都会在 P 的列空间内。

投影矩阵 P 的性质：

- $P^2 = P$ ，幂等， $P(P\mathbf{b}) = P\mathbf{b}$
- $P^T = P$ ，对称

Q: 现在考虑这个问题：线性方程组 $A\mathbf{x} = \mathbf{b}$ 无解的时候，即 $\mathbf{b} \notin C(A)$ ，如何求一个近似（最优解）？

A: 有了投影我们就可以把 \mathbf{b} 投影到 $C(A)$ 中得到 $\hat{\mathbf{b}}$ ，从而 $A\hat{\mathbf{x}} = \hat{\mathbf{b}}$ 有解， $\hat{\mathbf{x}}$ 即为一个近似解。

那么问题随之而来，如何得到 $\hat{\mathbf{b}}$ ？也就是问这里的投影矩阵 P 如何求得？

观察上图，我们发现有个误差向量 $\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ ，在本例中，它是垂直于 $C(A)$ 的，在讲四个子空间时我们说过 $C(A) \perp N(A^T)$ ，因此， $\mathbf{e} \in N(A^T)$ ，有：

$$A^T(\mathbf{b} - A\hat{\mathbf{x}}) = 0$$

$$A^T\mathbf{b} = A^T A\hat{\mathbf{x}}$$

我们希望这个方程有解，也就是求出 $\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$ 。问题是 $A^T A$ 的可逆性需要进一步讨论，即可能是可逆的也可能是不可逆的。那么 $A^T A$ 这个方阵可逆的条件是什么？答案是当且仅当 A 各列线性无关时， $A^T A$ 可逆

（ A 为 $m \times n$ 的矩阵， $A^T A$ 就是一个 $n \times n$ 的对称方阵）。下面给出证明。

证明：

不妨先假设 $A^T A\mathbf{x} = \mathbf{0}$ ，即有： $\mathbf{x}^T A^T A\mathbf{x} = 0 \Rightarrow (A\mathbf{x})^T A\mathbf{x} = 0$ ，即 $\|A\mathbf{x}\| = 0 \Rightarrow A\mathbf{x} = \mathbf{0}$

又 A 各列线性无关，所以 $A\mathbf{x} = \mathbf{0}$ 只有零解（线性无关的定义），所以 $\mathbf{x} = \mathbf{0}$ 。即 $A^T A\mathbf{x} = \mathbf{0}$ 只有零解， $A^T A$ 中各列线性无关， $R(A^T A) = n$ ，满秩矩阵一定可逆（秩的定义， $|A^T A| \neq 0$ ），得证。

好了，我们已经得到了 $\hat{\mathbf{x}}$ 的表达式，现在就可以求出投影矩阵了。

$$\hat{\mathbf{b}} = A\hat{\mathbf{x}} = A(A^T A)^{-1} A^T \mathbf{b}$$

这里的投影矩阵

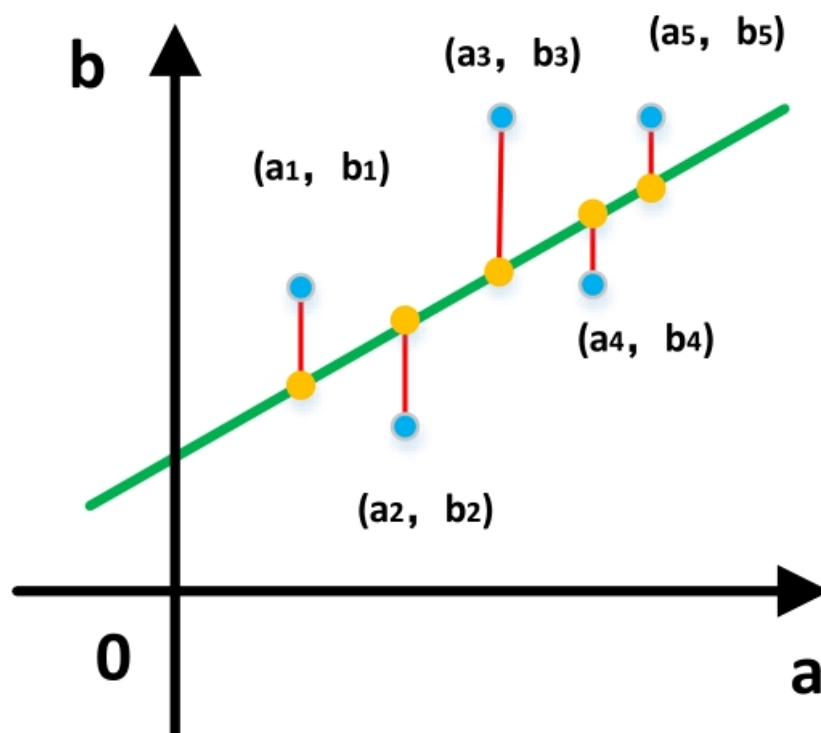
$$P = A(A^T A)^{-1} A^T$$

P 依旧满足投影矩阵的两个性质。特别的，当 $\mathbf{b} \perp C(A)$ ， $P\mathbf{b} = \mathbf{0}$ 。

6.4 最小二乘(Least Squares)

最小二乘的思想最小化理论测与观测值的平方和： $\min \sum_0^n y - y_i$

给定一系列二维平面上的点，要拟合一条直线 $y = kx + b$ ， k, b 未知；就用到了最小二乘。下面先讨论使用最小二乘拟合直线，再进一步探讨最小二乘与投影的奇妙联系。



$$\begin{aligned} kx_1 + b &= y_1 \\ kx_2 + b &= y_2 \\ &\vdots \\ kx_m + b &= y_m \end{aligned}$$

写成矩阵形式就是

$$A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \dots & \dots \\ x_m & 1 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{pmatrix}, \mathbf{x} = \begin{pmatrix} k \\ b \end{pmatrix}$$

求解方程组 $A\mathbf{x} = \mathbf{b}$ 。接下来我们讨论这个方程无解的时候该怎么办？即根本没有一条直线同时经过上图中所有蓝色的点！为了选取最合适的 \mathbf{x} ，让该等式“尽量成立”，引入残差平方和函数 H ：

$$\min(H) = \arg \min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

（下标表示2范式，上标表示平方）。这也就是最小二乘法的思想。当 \mathbf{x} 取最优值的时候， $A\mathbf{x}$ 恰好对应图中线上橙色的点，而 \mathbf{b} 则对应图中蓝色的点， \mathbf{e} 的值则应红色的线长。

现在的问题是如何求最优的 \mathbf{x} ？我们可以求关于 \mathbf{x} 的导数，并令其结果等于0，即：

$$y = \|A\mathbf{x} - \mathbf{b}\|_2^2 = (A\mathbf{x} - \mathbf{b})^T (A\mathbf{x} - \mathbf{b}) = \mathbf{x}^T A^T A \mathbf{x} - \mathbf{x}^T A^T \mathbf{b} - \mathbf{b}^T A \mathbf{x} + \mathbf{b}^T \mathbf{b}$$

$$\frac{\partial y}{\partial \mathbf{x}} = 2A^T A \mathbf{x} - 2A^T \mathbf{b} = 0$$

即最优 \mathbf{x} 满足 $A^T A \mathbf{x} = A^T \mathbf{b}$ ，是不是有点眼熟？

投影与最小二乘的联系

最小二乘的思想是想如何选取参数 \mathbf{x} 使得 H 最小。而从向量投影的角度来看这个问题， $H = \|\mathbf{b} - A\mathbf{x}\|^2$ 就是向量 \mathbf{e} 长度的平方(参考6.3的图)，如何才能使 \mathbf{e} 的长度最小呢？ \mathbf{b} 和 $\mathbf{x}_1, \mathbf{x}_2$ 都是固定的，当然是 \mathbf{e} 垂直 $\mathbf{x}_1, \mathbf{x}_2$ 平面的时候长度最小！换句话说：最小二乘法的解与矩阵投影时对变量求解的目标是一致的！最小二乘的求解实质上就是 $A\mathbf{x} = \mathbf{b}$ 没有解，我们就把 \mathbf{b} 投影到 $C(A)$ 内，此时误差向量或者说 H 最小（垂直于 $C(A)$ ）。

7. 正交矩阵与正交化法

7.1 正交矩阵（只讨论实矩阵）

注意：Strang教授在视频中讲正交矩阵时，谈到了非方阵的正交矩阵，而张贤达的《矩阵分析与应用》一书中对正交矩阵的定义仅限于方阵。下面以教授视频教授的为主。

定义： A 为 $m \times n$ ，若 $A^T A = I$ ，则 A 为正交矩阵，即 A 中的列向量两两正交且模长为1！（列向量是标准正交向量组）当 A 为 n 阶方阵，可得 $A^T = A^{-1}$ 。


举个正交矩阵的例子： $\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$

当某个向量投影到 $C(A)$ 中时，投影矩阵 $P = A(A^T A)^{-1} A^T = A A^T$ ，当 A 为方阵， $A^T A = A A^T = P = I$ ，投影矩阵是单位阵。

考虑 $A^T A \hat{\mathbf{x}} = A^T \mathbf{b}$ 当 A 为正交矩阵时， $\hat{\mathbf{x}} = A^T \mathbf{b}$ ， $\hat{x}_i = \mathbf{a}_i^T \mathbf{b}$ ， $\hat{\mathbf{x}}$ 的第 i 个分量等于 A 中第 i 列的列向量与 \mathbf{b} 的内积。可以看到当 A 为正交矩阵时，求解 $A\mathbf{x} = \mathbf{b}$ 形式非常简单，那给定一个非正交矩阵 A ，如何把它化为正交矩阵呢？这就是下一节讨论的正交化法。

7.2 Gram-Schmidt 正交化法

首先考虑两个不垂直的向量 \mathbf{a}, \mathbf{b} ，如图所示：



现在的问题是，在这两个向量构成的空间中，求出一组标准正交基，即求 \mathbf{p}, \mathbf{q} 使得 $\mathbf{p} \perp \mathbf{q}$?

不妨令 $\mathbf{p} = \mathbf{a}$ ，那么与 \mathbf{a} 垂直的向量该如何求？之前投影讲到， \mathbf{b} 投影到 \mathbf{a} 上时，误差向量 \mathbf{e} 是垂直于 \mathbf{a} 的。

$$\mathbf{q} = \mathbf{e} = \mathbf{b} - \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T\mathbf{a}}\mathbf{b} = \mathbf{b} - \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}\mathbf{a}$$

$\mathbf{q} \perp \mathbf{a}$

$\mathbf{a}^T\mathbf{b}$ 是一个常数，那么 \mathbf{a} 放在左右也就无所谓了，写成内积形式即：

$$\mathbf{b} - \frac{\langle \mathbf{a}, \mathbf{b} \rangle}{\langle \mathbf{a}, \mathbf{a} \rangle} \mathbf{a}$$

如果三个向量呢，第三个向量减去 \mathbf{a} 、 \mathbf{b} 上的分量就可以了。之后对所得向量除以模长即可得到标准正交向量组。这就是Gram-Schmidt正交化。

我们可以看到，本质上正交化就是求给定矩阵 \mathbf{A} 列空间 $C(\mathbf{A})$ 的一组标准正交基。

7.3 QR分解

给定向量组 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ ，向量组构成的矩阵 \mathbf{A} ，对向量组正交化后得到 $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$ ，正交向量组组成矩阵 \mathbf{Q} ，那 \mathbf{A} 与 \mathbf{Q} 有何关联？事实上 $\mathbf{A} = \mathbf{Q}\mathbf{R}$ ，矩阵 \mathbf{R} 是一个上三角矩阵，由于 \mathbf{q}_i 是 $C(\mathbf{A})$ 的一组标准正交基，因此 \mathbf{A} 中的每个列向量都是由 \mathbf{q}_i 的线性组合构成， \mathbf{R} 恰好是 \mathbf{q}_i 线性组合的系数。

$$\mathbf{R} = \begin{pmatrix} \mathbf{q}_1^T \mathbf{x}_1 & \mathbf{q}_1^T \mathbf{x}_2 & \dots & \mathbf{q}_1^T \mathbf{x}_n \\ 0 & \mathbf{q}_2^T \mathbf{x}_2 & \dots & \mathbf{q}_2^T \mathbf{x}_n \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \mathbf{q}_n^T \mathbf{x}_n \end{pmatrix}$$

$$\mathbf{Q} = (\mathbf{q}_1 \quad \mathbf{q}_2 \quad \dots \quad \mathbf{q}_n)$$

8. 行列式及其性质

9. 方阵的特征值与特征向量

注意：特征值与特征向量都是针对方阵而言！

9.1 方阵的特征值

给定 n 阶方阵 A ，若存在非零向量 $\mathbf{x} \in \mathbb{R}^n$ ，以及实数 $\lambda \in \mathbb{R}$ ，有：

$$A\mathbf{x} = \lambda\mathbf{x}$$

则称 λ 为 A 的特征值 (eigenvalue)，非零向量 \mathbf{x} 为 A 对应于 λ 的特征向量 (eigenvector)。特征向量经过矩阵 A 的变换后，方向没有发生改变，只是模长发生了改变，这就是特征向量的神奇之处。

给定 n 阶方阵 A ，现在考虑任意向量到 $C(A)$ 的投影矩阵 $P = A(A^T A)^{-1} A^T$ 的特征向量与特征值？上面讲过特征向量是经过矩阵变化后方向不发生改变，那什么向量经过 P 的变换方向不变？答案就是任意位于 $C(A)$ 内的向量，很容易理解在 $C(A)$ 内的向量到 $C(A)$ 的投影是向量本身，而且特征值为 1。

$$P\mathbf{x} = \mathbf{x}, \mathbf{x} \in C(A)$$

考虑置换矩阵 $A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ 的特征值和对应的特征向量。

显然 $\mathbf{x} = (1, 1)^T$ 是，交换行后方向没发生变化， $\lambda = 1$ ； $\mathbf{x} = (1, -1)^T$ ， $\lambda = -1$ 。

很重要的两个定理：

- n 阶方阵 A 的特征值之和等于对角线元素之和 (迹 trace)。
- $\lambda_1 + \lambda_2 + \dots + \lambda_n = |A|$ 特征值之和等于 $|A|$

如何求解方阵的特征值和特征向量

$$(A - \lambda I)\mathbf{x} = \mathbf{0}, \mathbf{x} \neq \mathbf{0}$$

即对于上述方程称之为特征方程，若存在非零解，矩阵 $A - \lambda I$ 务必不是满秩矩阵（必须存在自由变量），降秩矩阵也就意味着是奇异矩阵（不可逆矩阵），即 $|A - \lambda I| = 0$ ，现在只需计算行列式的值就可求出 λ ，之后再带回原方程，得到对应的特征向量。

- 例子：给定 $A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ ，求对应的特征值与特征向量。

$$|A - \lambda I| = \begin{vmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{vmatrix} = 0, \lambda_1 = 4, \lambda_2 = 2$$

当 $\lambda_1 = 4$ ，对应的方程：

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

解得 $\mathbf{x}_1 = (1, 1)^T$ ；

当 $\lambda_2 = 2$ ，解得 $\mathbf{x}_2 = (1, -1)^T$ 。

显然，若 \mathbf{x}_i 是矩阵 A 对应于 λ_i 的特征向量，则 $k\mathbf{x}_i$ ($k \neq 0$) 也是对应于 λ_i 的特征向量。

A 与 A^T 的特征值相同： $|A - \lambda I| = |(A - \lambda I)^T| = |A^T - \lambda I| = 0$

旋转矩阵的特征值与特征向量

上三角矩阵和下三角矩阵的特征值

当 A 为一个上三角矩阵时, 根据行列式性质 $|A - \lambda I|$ 的值恰好为 $(a_{11} - \lambda_1)(a_{22} - \lambda_2) \dots (a_{nn} - \lambda_n) = 0$, 因此上/下三角矩阵的特征值即为对角线元素。

9.2 相似矩阵

在线性空间中, 相似矩阵就是同一个矩阵的不同基下的表示。

设 A, B 是 n 阶矩阵, 若存在可逆矩阵 P , 使得 $P^{-1}AP = B$ 成立, 称 A 与 B 相似。

$$Ax = \lambda x, B = P^{-1}AP$$

$$P^{-1}APP^{-1}x = \lambda P^{-1}x \Rightarrow B(P^{-1}x) = \lambda(P^{-1}x)$$

由此可以看出, 相似矩阵的特征值相同, x 为 A 的特征向量, 那么 B 的特征向量等于 $P^{-1}x$ 。

9.3 矩阵对角化和矩阵幂乘

讨论下面内容的大前提: n 阶方阵 A 存在 n 个线性无关的特征向量 $\Leftrightarrow A$ 有 n 个互不相等的特征值 (没有重复的特征值)。如果存在重复的特征值, 可能存在也可能不存在 n 个线性无关的特征向量。(存在相同的 k 个特征值, 求出来的特征向量可能是同一个, 或者个数小于 k)

$S^{-1}AS = \Lambda$ (A, Λ 相似), S 是 A 对应的特征向量按列组成的矩阵, Λ 是由特征值组成的对角阵。这一过程被称为矩阵的对角化。需要注意: 矩阵 A 可以被对角化的充要条件是 A 存在 n 个线性无关的特征向量 (S 可逆)。谨记!

$$AS = A(x_1 \ x_2 \ \dots \ x_n) = (Ax_1 \ Ax_2 \ \dots \ Ax_n) = (\lambda_1 x_1 \ \lambda_2 x_2 \ \dots \ \lambda_n x_n) = S\Lambda$$

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \lambda_n \end{pmatrix}$$

$$AS = S\Lambda \Rightarrow S^{-1}AS = \Lambda \Leftrightarrow A = S\Lambda S^{-1}$$

矩阵幂乘

$$A^2 = AA = S\Lambda S^{-1}S\Lambda S^{-1} = S\Lambda^2 S^{-1}$$

$$A^n = S\Lambda^n S^{-1}$$

若 $Ax = \lambda x$, 那么 $A^2x = \lambda Ax = \lambda^2 x$ 。即 A 的 n 次幂对应的特征向量没有发生改变, 特征值为 Λ 的 n 次幂。

10. 对称矩阵与正定矩阵

10.1 对称矩阵的特征值与特征向量

$A = A^T$, 则称 n 阶方阵为对称矩阵。

- 对称矩阵的特征值都是实数

- 若 $\lambda_1 \neq \lambda_2$, $\mathbf{x}_1, \mathbf{x}_2$ 为其对应特征向量, 则 \mathbf{x}_1 与 \mathbf{x}_2 正交, 也就是说特征值不同的特征向量两两正交, 当特征值重复的时候, 求出的特征向量未必正交 (但是与其他不同特征值的特征向量仍然正交), 但可以通过正交化, 化为正交向量。也就是说, 特征矩阵总存在一个由特征向量组成的正交矩阵。

$$\begin{aligned} A\mathbf{x}_1 &= \lambda_1 \mathbf{x}_1, A\mathbf{x}_2 = \lambda_2 \mathbf{x}_2 \\ (A\mathbf{x}_1)^T &= \mathbf{x}_1^T A^T = \lambda_1 \mathbf{x}_1^T \\ \lambda_1 \mathbf{x}_1^T \mathbf{x}_2 &= \mathbf{x}_1^T A\mathbf{x}_2 = \lambda_2 \mathbf{x}_1^T \mathbf{x}_2 \\ (\lambda_1 - \lambda_2) \mathbf{x}_1^T \mathbf{x}_2 &= 0 \end{aligned}$$

若 $\lambda_1 \neq \lambda_2, \mathbf{x}_1^T \mathbf{x}_2 = 0$, 即 $\mathbf{x}_1, \mathbf{x}_2$ 正交。

在将矩阵对角化时: $S^{-1}AS = \Lambda \Rightarrow A = S\Lambda S^{-1}$, 若 A 为对称矩阵, 那么 S 中列向量两两正交, 1 可知 $S^T S = I$, 进而 $S^T = S^{-1}$ 。因此, $A = S\Lambda S^{-1} = S\Lambda S^T$ 。这就是谱分解。

例子: 图的拉普拉斯矩阵 L 就是一个对称矩阵, $L = U\Lambda U^T$, 利用 U 可以对节点进行图上傅里叶变换和反傅里叶变换。

10.2 正定矩阵 (positive definite matrix)

讨论完对称矩阵的特征值, 我们知道一定是实数, 我们另一个比较关心的是特征值的正负问题, 这就讲到了正定矩阵。下面给出正定矩阵的定义。

给定对称矩阵 A , 非零向量 \mathbf{x} , 若满足:

$$\mathbf{x}^T A \mathbf{x} > 0, \mathbf{x} \neq \mathbf{0}$$

则称 A 为正定矩阵。当 $\mathbf{x}^T A \mathbf{x} \geq 0$, 我们称 A 为半正定矩阵 (positive semi-definite matrix)。 $\mathbf{x}^T A \mathbf{x}$ 为二次型。

正定矩阵的性质:

- 特征值均为正数, 也就意味着行列式值为正数
- A, B 为正定矩阵, $A + B$ 也为正定矩阵

若 $A_{m \times n}$, 考虑 $A^T A$ 是 n 阶方阵, 是对称矩阵, 且至少是半正定矩阵 (矩阵元素全为 0 的时候)。

$$\mathbf{x}^T A^T A \mathbf{x} = (A\mathbf{x})^T (A\mathbf{x}) = \|A\mathbf{x}\|^2 \geq 0$$

11. 奇异值分解

12 线性变换

设 T 是一个从 V_n 到 U_m 的映射, 若 T 满足:

- $T(\lambda v) = \lambda T(v)$
- $T(u + v) = T(u) + T(v)$

就称从 V_n 到 V_m 的线性映射或线性变换。

坐标 (coordinate): $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 是线性空间 V_n 的一组基, 对于 $\mathbf{u} \in V_n$, $\mathbf{u} = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n$ (基向量的线性组合), $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$ 称为这个基下的坐标。

例子: 对于 $T(\mathbf{x}) = A\mathbf{x}, \mathbf{x} \in \mathbb{R}^n, A_{m \times n}$, 就是一个线性变换, 考虑 A 是如何构成的?

对于 $\mathbf{x} \in \mathbb{R}^n$ ，有一组基 \mathbf{v}_i 描述，坐标为 $\boldsymbol{\alpha}$ ，对于 $T(\mathbf{x}) \in \mathbb{R}^m$ ，有一组基 \mathbf{w}_i 描述，坐标为 $\boldsymbol{\beta}$ 。

可知 $\mathbf{x} = \boldsymbol{\alpha}^T \mathbf{v}$, $T(\mathbf{v}_1) = \beta_{11} \mathbf{w}_1 + \beta_{21} \mathbf{w}_2 + \dots$ ，即坐标构成了第一列，同理第二列、第三列....这是线性变换的矩阵形式。

注意：求导也是一种线性变换。

13. 矩阵与向量微分

根据函数值类型的不同可以分为：标量函数、向量函数、矩阵函数；根据输入类型的不同：标量、向量、矩阵，两两组合可以分为：标量函数对标量的导数、标量对向量的偏导（比如梯度）、标量对矩阵的偏导；向量对标量的偏导、向量对向量的偏导、向量对矩阵的偏导等等。

关于向量微分，转置与否对结果有很大影响，本章讨论时，统一以输入的形状为准，即当输入是列向量，偏导结果仍为列向量；输入是行向量，偏导结果仍为行向量。

13.1 标量对向量的偏导

$f(\mathbf{x}) \in \mathbb{R}$, $\mathbf{x} \in \mathbb{R}^n$, $\frac{\partial f}{\partial \mathbf{x}} = (\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n})^T$ 称为梯度向量。

黑塞矩阵 **Hessian Matrix**

$\frac{\partial f}{\partial \mathbf{x}^2}$ 称为黑塞矩阵，即 f 对多元变量的二阶偏导所构成的矩阵。黑塞矩阵与多元函数的极值判定密切相关。

$$H = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

即： $H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$ 。

13.2 向量对向量的偏导

注意向量对向量的偏导结果是一个矩阵。

$f(\mathbf{x}) \in \mathbb{R}^m$, $\mathbf{x} \in \mathbb{R}^n$, $\frac{\partial f}{\partial \mathbf{x}} = \frac{\partial(y_1, y_2, \dots, y_m)}{\partial(x_1, x_2, \dots, x_n)}$ 称为雅可比矩阵

雅可比矩阵 **Jacobi Matrix**

$$\begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \frac{\partial y_m}{\partial x_2} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

可知雅可比矩阵的形状： $m \times n$ 。

二次型的偏导

$$f(\mathbf{x}) = \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{x} + r, r \in \mathbb{R}$$

阅读中发现错误请联系: nefuzzyj@163.com, 不胜感激!